大队长 · AI产业周期研究

AI变现与编程TAM

收费如何形成收入，收入又怎样转成可持续现金。

V1.5.1 · 正文修订
2026-10-09

按本篇主题组织证据与分析
个人研究 · 基于公开信息 · 不构成投资建议

免责声明与阅读边界

本报告为“大队长”基于公开资料形成的个人研究，不代表任何任职机构观点，不构成个性化投资建议、收益保证或交易指令。技术和商业判断可能错误，信息也可能随后修订。

V1.5.1为V1.5基础上的增量正文修订版，增量资料检索截止2026年10月9日上午；各项财务、统计、行情与政策数据以正文明确的期间或观察日为准，不能全部理解为该日现值。公司指引、研究假设和已实现结果分开阅读；缺失的原始证据不以推测填补。

本版按主题重编，不沿用旧版分页；旧版与历史档案保留不改。历史评分和预测记录只用于追溯，未完成统计校准的数字不属于经过验证的崩盘概率。审计条目总数不等于本轮全部事实复核通过。

本版修订说明

1. 变现篇：新增Haiku 5.5按请求长度分档的价目及算例，更新Sonnet缓存费；视觉广告测试不当作已确认收入。

逐项勘误与修订见文末《本版逐项修订记录》，可从目录跳转。

2026-09-08编排勘误：本册正文从第一章起连续编号，目录和当前章节引用同步；导读不占章号。母稿对应关系见文末“分册编号勘误”，研究数据与结论未因本次编排修改。

目录

目录及页码依据本版正文生成；PDF内可点击跳转。

第一章：AI靠什么赚钱？——变现版图与编程TAM 4

本篇内容地图与逻辑链 4

1.1 14个变现领域：按收费机制分类，不再混排规模榜 4

1.2 云与广告：最成熟的收费渠道，不等于全部都是AI收入 5

1.3 模型层和企业订阅：增长已出现，利润结论仍要等账 6

1.4 编程市场TAM：保留席位模型，取消“绝对上限” 7

1.5 编程之外：按工作流寻找可续费的需求 9

1.6 全球资本开支三层拆解：保留结构，修正回收模型 10

1.7 API定价与收入方程：从“死亡螺旋”改为可检验情景 11

1.8 单位经济与客户ROI：让利润、现金和价值各归各位 13

1.9 2026年余下阶段与2027年的核验表 13

1.10 我可能错在哪里 14

本版逐项修订记录 15

分册编号勘误 · 2026-09-08 15

AI变现与编程TAM：逐项修订 15

第一章：AI靠什么赚钱？——变现版图与编程TAM

本篇口径：V1.5.1正文修订，增量检索截至2026年10月9日上午（北京时间）。美元数字中，B代表十亿美元；1B等于10亿美元。公司披露的ARR（年度经常性收入指标）、run-rate（按近期经营速度年化）与财报已确认收入分开使用，不能互相替代。本轮更新Haiku分档价格、Sonnet缓存调价和广告测试计划，既有收入保留原披露期，不用产品发布代替财报。

本篇内容地图与逻辑链

AI商业化已经不只发生在编程工具里。企业生产力订阅、客服智能体和对话广告都出现了可以核对的收费或经营指标，因此本篇撤回“编程是唯一被验证的大市场”以及“API降价必然使行业收入持续下降”的判断。更难回答的问题是：这些收入中有多少来自终端客户，有多少在云、模型与应用之间重复出现；客户付费能否覆盖部署和复核成本；平台在重度使用增加时，能否同时留下毛利和现金。

研究问题	落点	本版结论与边界
谁在付钱，卖的是什么	1.1—1.3	分清云服务、广告、订阅与API；整体业务收入不冒充纯AI收入
编程市场到底有多大	1.4	固定席位只是一个情景；按量收费已经出现，原“绝对上限”不成立
编程以外能否赚钱	1.5	逐个看合同、续费和交付成本；不从估值推断经营规模
收入能否消化资本投入	1.6—1.8	用资产批次、服务成本和现金流建模，不再把收入/资本开支比称为IRR
什么事实会改变判断	1.9—1.10	观察同口径增长、付费留存、成功任务成本与回收期；未知保留未知

本篇没有给出“所有AI收入合计”，因为现有公开披露不足以完成全链条抵销。一个企业给应用公司付款，应用公司向模型公司买API，模型公司再向云厂租算力，三层都可能确认收入，但不能据此认定社会终端支付了三遍钱。这个缺口影响的是总量测算的可信度，不是否认各层真实提供了服务。

1.1 14个变现领域：按收费机制分类，不再混排规模榜

原表把收入、运行率、投资额与公司估值放在同一列，排出的名次没有可比意义。下面保留14类覆盖范围，改看客户、收费单位以及仍缺什么证据。已经有产品收费，不等于产品利润为正；一家公司的净利润为正，也不能证明其每个AI产品盈利。

领域	主要付费方与收费单位	可用证据	不能直接推出什么
云算力与模型托管	企业、模型公司；算力时长、token及承诺用量	云分部收入，部分专项AI run-rate，见1.2	云整体收入不是纯AI收入；长期承诺不是已收现金
广告优化	广告主；展示、点击或转化	广告收入、展示量与单价；ChatGPT Ads新增披露，见1.2	全部广告增长不能归因于AI；广告主流水不是平台收入
企业生产力	企业；席位加额外用量	M365 Copilot付费席位，见1.3	席位×标价不能冒充实际ARR或利润
聊天订阅与API	消费者、开发者及企业	公司run-rate、API费率，见1.3与1.7	年化速度不是已完成全年收入

领域	主要付费方与收费单位	可用证据	不能直接推出什么
编程与开发智能体	开发者、工程组织；席位、用量及任务	订阅、计费规则、部分收入增速，见1.4	注册用户不是付费开发者；生成代码不是验收产出
客服与CRM	企业；席位、会话、动作或成功解决量	Agentforce ARR及口径说明，见1.5	计费动作数不等于独立客户数，也不等于成功解决数
法律科技	律所与企业法务；用户、文档或项目	具名部署、采购与续费应逐项核查	部署公告不能替代合同金额与法律责任成本
金融研究与信息	金融机构及企业；内容订阅和工作流	AlphaSense公司ARR历史锚，见1.5	数据许可、专家网络等收入不全是新增生成式AI收入
医疗文书与辅助诊断	医院、医生或支付方；席位、就诊次序	采购合同、实际使用、临床评价	签约额不等于已确认收入；节时不等于诊疗质量提高
音频、视频与内容生成	创作者、企业；订阅、时长、生成量	ElevenLabs公司ARR，见1.5	内容全市场规模不等于生成工具可收费规模
教育	学生、家庭、学校；订阅或课程	付费留存、考试与学习效果	传统教育应用全部收入不属于AI新增收入
自动驾驶与机器人	乘客、物流和工业客户；运量、工时或设备	付费运营许可、单位作业成本与交付	估值、融资及演示不能替代可复制的经营利润
科研与生物医药	药企、实验室；服务、授权及里程碑	已收服务费、研发里程碑和临床结果	合同最大里程碑金额不是当前收入
主权AI与防务	政府及承包商；项目和维护合同	拨款、签约、履约与验收	预算意向不是订单，订单不是当期财政付款

后八类不是被统一判为“仍在烧钱”，而是缺少足够一致的公开数据来做行业利润排名。研究可以先跟踪客户价值和合同兑现，再决定哪些公司值得建立盈利模型，不能用同一个ARR标签把所有场景磨平。

1.2 云与广告：最成熟的收费渠道，不等于全部都是AI收入

1.2.1 云分部实际收入与AI专项披露

公司及统计期	已确认收入或经营指标	AI归因边界
Amazon AWS，2026Q2	收入42.232B，营业利润16.621B，利润率复算39.4%	公司称AI业务run-rate超过25B；它包含在业务体系内，不能与AWS收入再加总
Microsoft Azure，FY2026全年	公司披露全年收入超过100B，增长41%	Azure不等于Intelligent Cloud部门，也不等于Microsoft Cloud，更不是纯AI收入
Google Cloud，2026Q2	收入24.768B，营业利润8.814B，利润率复算35.6%	公司把AI基础设施、AI解决方案与核心GCP服务并列为增长来源，没有给出可抵销的纯AI收入表

来源：Amazon第二季度财报、Microsoft官方电话会、Alphabet第二季度财报第2页。三行统计期间不同，刻意不做合计或排名。

这组数字证明平台具备真实收费能力和分部盈利，并不能单独说明本轮新增算力的资本回报率。成熟数据库、存储、网络及既有客户的利润可以与新AI业务共存；如果拿全云分部利润去覆盖新增AI资产，再声称每一批新资产已经回本，会把存量利润垫成新投资的证据。

AWS另行披露AI业务与芯片业务的run-rate都超过25B。芯片业务涵盖的工作负载与AI业务可能交叉，在公司未提供抵销表前，两项不能相加为“50B新增AI收入”。同样，云厂给模型公司提供的融资可能支持客户付云账单，需继续追踪现金来源，但不能因此把客户实际消耗算力的收入一概判为虚假。

1.2.2 广告的两种AI变现方式

2026Q2，Meta广告收入59.363B，Google广告收入81.629B，合计140.992B；这个合计只说明两个广告业务的季度规模，不是生成式AI收入。Meta同时披露广告展示量增长14%、平均单价增长12%，收入变化可以从量与价拆解，但需要实验或经营分项，才能进一步分辨AI推荐、宏观广告需求、客户结构和汇率的贡献。来源：Meta季度财报、Alphabet季度财报。

一种变现是在原有广告业务里提高转化或降低广告主获客成本；另一种是在新AI入口直接卖广告。OpenAI于2026年8月31日披露，ChatGPT Ads推出不足200天，年化收入运行率达到1B。这是比“AI优化了4000亿美元广告盘子”更直接的新增收费证据，但它仍不是全年广告收入已经达到1B，也没有独立披露广告业务利润。来源：OpenAI广告业务公告。

广告模式能补贴免费用户的推理成本，也会引入新的约束：广告库存、商业意图和转化测量是否充足，增加商业内容是否损害用户信任，以及新的广告预算是否只是从其他平台转移。对单个平台，抢到份额可以增长；对整个产业，预算转移不能被算成同等规模的新终端需求。

10月5日OpenAI又公布图像生成场景的视觉广告，计划当月稍后在美国Free/Go用户中测试，并扩展归因与增量效果测量合作。这使广告变现具备更多可测试的场景，但新格式并非已全面上线，公告也没有新增广告收入或利润数字；特定广告主的效果案例不能外推成全平台投资回报。OpenAI广告与测量更新

1.3 模型层和企业订阅：增长已出现，利润结论仍要等账

1.3.1 先分清三个“年收入”

财报收入对应已经履约的统计期间。ARR是公司对经常性合同收入所定义的年化指标，定义并不跨公司统一；run-rate则把最近一个月或季度的经营速度外推成年。高速增长企业的期末run-rate通常会高于过去一年的已确认收入，按量业务还会受客户集中采购、季节性和短期活动影响。

因此本篇保留披露日期，宁可把新值列为未决，也不把“目前公开核实到的旧锚”改写成“目前公司只做到这个规模”。

主体	本次直接核实的公开披露锚	如何使用
OpenAI	2026-03-31公司公告称每月收入2B	算术年化约24B，是3月时点经营速度，不是2025全年收入，也不是9月新值
Anthropic	2026-05-28公司披露当月run-rate突破47B；此前4月披露超过30B、2025年末约9B	同一公司披露显示增长，但未提供同口径经审计全年利润和现金流；47B不是9月即时值
Claude Code	2026-02-12公司披露run-rate超过2.5B	是Anthropic内的产品；不能再与母公司总额相加；不可冒充9月现值

主体	本次直接核实的公开披露锚	如何使用
M365 Copilot	2026-07-29官方电话会称付费席位超过3000万	是明确的付费覆盖证据；没有足够信息用统一牌价还原全部合同收入
ChatGPT Ads	2026-08-31公司披露广告run-rate1B	新商业渠道的收费证据，不再与OpenAI整体收入机械相加

来源：OpenAI3月公告、Anthropic5月H轮公告、Anthropic4月公告、Claude Code2月披露、Microsoft7月电话会、OpenAI8月广告公告。

Anthropic的5月47B锚已有官网一手披露，应替换只停在4月30B的旧口径。8月媒体报道Anthropic与OpenAI的run-rate进一步提高，但本次没有取得对应公司正式财务文件，不将这些报道升级为更晚的公司确认值。两家公司的收入确认方式、云渠道分成和股权相关收益仍需要原始会计政策及报表对照，不能从一篇转述稿先认定一家全部用总额法、另一家全部用净额法，再统一打七折“还原真实收入”。

1.3.2 收费增长为什么仍不等于单位经济跑通

把用户拉进产品，只解决了第一步。订阅收入相对稳定而使用量迅速增加时，每个付费席位消耗的推理、工具调用和人工支持可能上升，收入增长与产品毛利改善可以分开走；相反，缓存、模型路由和更低成本模型也可能使使用增长快于成本增长，利润不必随API标价下降。

财务模型应逐月跟踪：付费客户和付费席位、每席实际收入、额外用量收入、折扣与赠送额度、活跃率、取消或降档、推理与支持成本。只拿“付费席位×公开月费”计算ARR会忽略大客户折扣、年付时点、不同产品组合和试用安排，原文M365 Copilot“72亿美元ARR”因此退出当前事实表。

判断上，我现在更看重同一客户跨季度的付费用量和毛利，而不是用户总数。增长可能足够快，也可能主要由一批重度用户驱动；没有净收入留存、毛利和现金收款的配套数据，无法仅凭run-rate大小裁决最终赢家。

1.4 编程市场TAM：保留席位模型，取消“绝对上限”

1.4.1 人数基数与实际计费边界

原主报告把3650万专业开发者归给GitHub，出处有误。这个数字来自SlashData对2025年初的调查估算，同期总开发者约4720万；SlashData在2026Q1汇编中把总数更新为4840万，但本次未取得同口径更新后的专业开发者分项。以下继续用3650万作历史基数的敏感性测算，不称其为2026年9月精确人口。来源：SlashData2025人口研究、2026Q1汇编。

GitHub在Microsoft FY26Q4电话会中披露的平台用户与Copilot用户是另外两种统计对象，不能用注册平台账户替代职业人口，也不能把Copilot用户全算成付费用户。一个工程师同时订阅多个工具时，个人数要去重，但实际支付给不同供应商的费用可以分别记录；工具公司再向上游支付的模型费，则需要在全产业终端市场汇总时抵销。

2026年6月，GitHub开始把Copilot计费转向按token消耗的AI Credits，席位内含额度之外还可追加用量，旧年付合同存在过渡安排。这意味着市场已经不完全遵循“每名程序员每月只买一份固定20美元软件”的约束。来源：GitHub计费方案公告、6月上线说明。

1.4.2 旧模型重算：人数×渗透×单价

纯席位市场年收入 = 可触达专业人数N × 付费渗透率s × 月均实际收入P × 12。

下表是机械敏感性，不是市场预测。基数N=3650万，忽略新增非专业用户，假设每人只购一个产品，价格是情景变量而非任一公司的实际平均售价。

月均实际收入	25%付费渗透	50%付费渗透	100%付费渗透
10美元	10.95亿美元	21.90亿美元	43.80亿美元
20美元	21.90亿美元	43.80亿美元	87.60亿美元
30美元	32.85亿美元	65.70亿美元	131.40亿美元
40美元	43.80亿美元	87.60亿美元	175.20亿美元
100美元	109.50亿美元	219.00亿美元	438.00亿美元

原文“3650万×30美元×12”在不同位置被写成110亿美元、131亿美元或131B，统一更正为131.4亿美元，即13.14B。这个错误会把市场空间放大十倍，也说明不能只检查首页最新数据而保留正文公式与地图的旧结论。

席位模型仍然有用：它能问清客户规模、支付能力和份额假设。但它不是一个不受商业模式变化影响的硬天花板。重度企业可能把工具费归入研发预算，按任务或计算用量支付；非开发者可能只在建站、数据清洗或自动化项目期间付费，新增用户也未必全年留存。

1.4.3 扩展模型：不能既算席位又重复算同一笔用量

收入可以写成：基础席位收入＋超过内含额度的按量收入＋独立任务或服务收入－退款与折扣。其中“超过内含额度”很重要，如果某订阅已包含一部分token，再把该部分token价值加一遍，模型就高估收入。

举一个只用于计算的企业情景：有1000万付费席位，平均实际订阅费每月30美元，形成36亿美元年收入；每席全年额外消耗100美元，新增10亿美元，合计46亿美元。若另有100万非开发者每年只购买两个月、每月20美元，新增0.4亿美元，而不是把他们算成全年2.4亿美元订阅。这里的用户数、价格与消耗全是研究假设，没有被写成行业实际值。

任务计费还有另一条边界：用户愿意为完成一次迁移、修复或构建支付多少，取决于替代的总成本，而不是输出了多少代码。代码生成便宜可以扩大需求，但如果需求澄清、测试、上线、合规与维护仍依赖人，应用公司只能获取其中一部分价值。软件外包总市场不能无折扣搬成AI编程工具的收入空间。

1.4.4 当前竞争证据与估值方法

Cursor于2025年11月公司公告披露年化收入超过1B、该轮投后估值29.3B；其官网2026年3月Press索引转引Bloomberg关于2B年化收入的报道，证据性质仍是媒体报道。原文“500亿美元谈判估值”不再标作已经完成的当前估值，也不把2B当作全年经审计收入。来源：Cursor公司融资公告、Cursor Press索引。

Microsoft7月官方电话会披露GitHub Copilot收入环比增长超过60%，并指出新按量模式对收入和毛利有影响。这是“市场不只靠固定低价席位”的直接反向证据，但仍不足以复原其收入绝对额、利润和全部付费人数。Claude Code的母子产品重复统计也必须避免，不能把Anthropic全部收入再加上Code收入来估编程市场。

原文用“Cursor估值是传统TAM的数倍”直接判定泡沫，逻辑需要撤回：估值是未来现金流存量，TAM是每年收入流量，两者没有必须小于1的关系。真正应问的是未来可服务市场、份额、净利或现金利润率、竞争下的定价、资本消耗与股权稀释；高增长能否使目前的高倍数下降，以及增长放慢后利润能否接上。缺少这些输入，不给出貌似精确的公司合理估值。

1.4.5 生产力：不能把个人感受直接外推为TAM

一个反例值得保留。METR对16名熟悉自己代码库的开源开发者、246项任务做早2025年工具随机试验，允许使用AI时平均完成时间增加19%。这只适用于该工具版本、任务与样本，不能推出今天所有AI编程无效。METR在2026年2月的后续说明又明确指出，不愿在无AI条件下工作的开发者和任务退出实验、并行agent计时等问题，使新实验难以可靠估计加速幅度。来源：METR原始论文、后续实验说明。

所以我撤掉原文无条件的“效率提高5—10倍”。客户采购更适合测一项真实任务从提出到验收的总时间，包括提示词、复核、失败重试、集成和维护，并同时记录缺陷与风险。愿意付费说明客户看到了价值，不代表每个客户都已经把价值准确算成现金收益。

1.5 编程之外：按工作流寻找可续费的需求

1.5.1 客服与CRM：看结果，也看计量变化

Salesforce于2026年8月26日披露，Agentforce ARR超过1.5B，与Data360合计接近3.9B；公司同时说明本季Agentforce ARR纳入其AI offerings、Slackbot与Headless360。这比原0.8B更近，但产品口径已变化，不能把所有同比增幅视作同一产品自然增长，更不能将Agentforce、合计值和全公司收入相加。来源：Salesforce FY27Q2财报。

客服是容易形成闭环的场景，因为工单成本、解决率、人工转接率及投诉可以量化。研究时仍要警惕“动作数”指标：一个问题拆成十个动作，平台计费可能上升，但客户没有因此获得十个问题的解决。实际商业价值应落在成功解决、重复联系、处理时长和客户损失上，而不只看agent活跃。

1.5.2 法律与金融研究：付费能力来自责任和内容

Harvey官方新闻室在8—9月持续披露具名律所与企业部署，证明其不是只有演示；但部署公告没有提供足以重建当前ARR、回款或利润的统一财务明细。本版不把第三方不同日期的估算更新成一个新的“精确收入”。来源：Harvey新闻室。

法律工作流的价值不只是更快生成文本，还包括引用核验、案例权限、版本留痕和责任分配。金融研究同理，内容许可、专家访谈、公告检索和工作流已经有预算池。AlphaSense在2025年10月官方披露ARR超过0.5B，可作为历史收费锚，但它包括原有信息与工作流业务，不是0.5B纯AI新增收入，也不是9月最新值。来源：AlphaSense公司公告。

这些业务可能比通用聊天更有留存，却也承担数据授权、审查和企业销售成本。是否有定价权，要看客户会不会在下一份合同里继续付费、能否用更便宜的通用模型加现有内容替代，以及错误发生后谁承担成本。

1.5.3 音频与内容：把订阅增长和权利成本同时建模

ElevenLabs5月5日公司公告披露，2026年前四个月ARR超过0.5B，2025年末为0.35B。该页面后来标注8月31日更新，但收入句子的统计区间仍是前四个月，不能把它改成“截至8月底0.5B”。来源：ElevenLabs公司公告。

这类产品已有明确付费用户，却还要分创作者、企业客服和媒体制作：个人可能按项目订阅又取消，企业可能为低时延、授权声音和服务质量付高价；合成量增长还会带来推理、存储、审核和内容授权成本。不能用生成分钟数推全年订阅收入，也不能假定模型成本下降全部留给应用商。

1.5.4 医疗、教育与物理世界：确认价值的时间更长

医疗文书可以先看记录时长、复核率和病历质量，辅助诊断还需要临床安全与支付方认可；教育要看留存与学习效果，不能将某教育公司的所有订阅收入都贴成AI变现；自动驾驶、机器人则必须把人工接管、设备维护、保险及利用率算入单位作业成本。

科研和新药更容易出现“合同上限很大、近期现金很小”的情况。里程碑付款必须按条件、触发概率与时间拆开，项目合作证明对方愿意试，不等于药品已经上市。主权AI与防务也要区分意向、预算、合同、验收与收款，不能把政治优先级直接变成年收入预测。这些是不同的研究模型，不能用统一的“AI应用ARR”加总代替。

1.6 全球资本开支三层拆解：保留结构，修正回收模型

原来的算力芯片、数据中心物理层与电力层划分仍然有助于研究，只是不能把三层企业收入一加，就当作终端用户投入了同样多的新增资本。芯片卖给服务器厂，服务器卖给云厂，会在不同公司分别形成收入；设备购置、数据中心租赁与电力采购还可能分别落在资本开支、租赁和运营成本中。

层级	应记录的投入	回收与风险变量	与本篇变现端怎样对接
算力芯片及网络	设备购置、服务器和网络配置	有效利用率、服务年限、更新替换、单位任务成本	转化为可收费算力与成功任务，不以峰值性能直接推收入
数据中心物理层	土建、配电、冷却、机柜及租赁	达到可用状态日期、爬坡、建设成本、可转用性	未投运部分不能与已上线收入假定同年满产匹配
电力与接入	发电与电网投资、接入、长期购电	能否按期交付、价格、最低采购及弃电约束	电力瓶颈可能限制收入，也可能推迟开支，不必然导致需求消失

旧版引用的Goldman全球五年累计7.6T和Moody's特定云厂年度预测，样本、起止年及资产口径并不相同，本次未获得两份原始完整模型，因此不继续用它们作为“已经相互验证”的当前总盘子。尤其不能把一个覆盖全球的累计值称为已经签署的资本承诺，也不能用某几年占累计值23%就证明投资前置。

1.6.1 为什么旧“资本回收倍数”不能给出IRR

旧文把年终收入上限1.36—2.06T乘五，得到6.8—10.3T，再除以7.6T资本开支，称为资本回收倍数并判断IRR为负。这至少少了收入实现路径、运营费用、税、营运资金、投资发生日期和残值。收入不是可还给投资人的现金；折旧也不能在现金投资扣除后再当作现金流出重复扣减。

即使只检查数学，“五年线性达峰”也不能直接用终点乘五。假设年收入从零按连续直线升至R，第五年末达到R，五年累计收入面积为2.5R；若规定五个年末收入分别为0.2R、0.4R、0.6R、0.8R和R，离散合计为3R。两种定义都不是5R。它们只是例题，不能作为对真实AI产业收入的预测。

1.6.2 改用项目或资产批次现金流

在企业自由现金流口径下，FCFF = 税后经营利润＋折旧摊销－资本开支－营运资金增加；企业价值是这些未来FCFF和终值的贴现。项目回报则应按建设期投入、投产爬坡、收入、服务成本、更新资本和退出残值逐期列示。没有完整现金流时，应保留“回报未证实”，不能把粗糙收入比升级为收益率。

这也改变了周期判断的力度：资本开支高、云利润增长与应用收入增长可以同时发生，风险不自动消失；资本开支暂时放缓，也可能是接电和建设约束，不能自动解释为需求崩塌。真正需要跟踪的是已投运批次的收入利用率、服务毛利和回收周期，与下一批投入是否匹配。

1.7 API定价与收入方程：从“死亡螺旋”改为可检验情景

1.7.1 当前费率反映分层与缓存，不是统一归零

Anthropic9月发布的Fable5.1，标准未缓存输入与输出分别为每百万token10美元和50美元，缓存读取价从Fable5的1美元降为0.25美元；缓存写入仍另收费。这是特定产品、特定计价项目的降价，不是所有token都降75%，更不是同质量全市场价格每月下降15%。来源：Fable5.1发布说明、官方定价表。

费率还要注明有效期。Google9月2日公布Gemini 3.8 Flash每百万token输入0.75美元、输出3.75美元的推广价，脚注明确其于2026年12月31日到期，2027年1月1日起拟适用1.50美元和7.50美元。后者是已公告、尚未生效的价格，不能写成9月已涨价；前者也不能直接外推全年客户成本。预算应分期计价，并与任务耗用量和成功率一起复算。来源：Google发布说明及价格脚注。

原图把不同模型代际、不同能力和输入价连成一条“30美元跌到0”的曲线，且把开源模型直接记为零价格，当前撤回。开源权重可能免去部分授权费，但推理仍有服务器、能耗、运维和服务质量成本；不同tokenizer对相同文字计数也可能不同。研究质量调整后的价格，应固定任务、质量门槛、延迟和账单，而不只选最便宜的一项输入价。

9月22日的两组披露进一步说明，低价竞争与更低任务成本需要分别测量。下表为标准API每百万token的美元标价，不是已实现平均收入，也不代表各模型能力相等。

9月22日发布的模型	未缓存输入	输出	缓存读取	限定条件
OpenAI GPT-6 Sol	2.00	10.00	0.20	提示输入不超过272k token的标准价
OpenAI GPT-6 Luna	0.10	0.50	0.01	同上；不同能力层级，不作同质量降价比较
Anthropic Claude Opus 5.5	4.00	20.00	0.20	标准模式；缓存写入、快速模式另计

来源：OpenAI 9月22日官方变更记录、Anthropic Opus 5.5发布与价目。Anthropic上一代Opus 5的输入、输出为5和25美元，缓存读取0.50美元，因此前两项下降20%、缓存读取下降60%；公司所称典型工作成本降低40%，还包含任务耗用量变化，是厂商测试结论，不是本报告独立实测，更不是毛利提高40%。

预算例题可以保持简单：若一批请求均符合上述上下文条件，合计100万未缓存输入和20万计费输出token，Sol账单为4美元，Luna为0.20美元，Opus 5.5为8美元。这里只比较固定用量账单；一旦任务成功率、重试、工具、缓存和人工复核不同，便不能按这个比例宣布真实交付成本下降。价格下降可能扩大付费任务，也可能侵蚀模型商的单位收入，最终仍要用留存、用量与成本一起验证。

10月1日版记录的Sonnet 5.5输入、输出、缓存读取价为每百万token 2、10、0.20美元；其中缓存价已被10月7日调价接续，不能继续当现价。9月29日GPT-6.1 Sol披露的输入、输出为2和10美元，缓存输入0.10美元，保留该发布时点。固定100万未缓存输入、20万输出的简化账单仍为4美元，缓存读取降价并不改变这个没有缓存的例题。Sonnet 5.5、GPT-6.1 Sol发布

10月7日Anthropic发布Haiku 5.5，同时将Sonnet 5.5缓存读取价降至0.10美元，较旧价下降50%，标准输入和输出价未变。10月9日回读的官方价目如下，均为每百万token美元价；这是收费规则，不是已实现单价或模型商毛利。Haiku发布及当日调价、当前价目与上下文分档

模型及每条请求的条件	未缓存输入	输出	缓存读取
Haiku 5.5，提示输入不超过100k token	0.10	0.50	0.01
Haiku 5.5，提示输入超过100k token	0.50	2.50	0.05
Sonnet 5.5，标准模式	2.00	10.00	0.10

Haiku的100k门槛按每条请求判断，包含缓存读写输入，不是只对超过门槛的部分加价。若10条请求各10万未缓存输入、2万输出，合计100万输入、20万输出，账单为0.20美元；若同一总量拆成5条各20万输入、4万输出的请求，每条都进入高档价，合计为1.00美元。缓存写入、工具等费用另计，实际成本还取决于成功率和重试。Sonnet多数智能体任务成本约降20%只是厂商给出的工作流效果，不能据此认定行业毛利率变化。

商业计费也在变。Microsoft 9月25日明确将Cowork、Code和Autopilot等长任务纳入按使用量计费，并提供预算和消耗管理；微软宣布Home、Code将在随后数周经Frontier分批推出，Autopilot计划月底扩大私人预览，本轮未另核实际覆盖范围。它让重任务有机会按消耗收费，却尚不能证明客户已经持续购买或贡献正毛利；不能把产品发布写成新增收入。Microsoft官方公告，“Managing AI spend”

1.7.2 离散增长要保留交叉项

对一个固定口径的收费品类，收入R=P×Q。若本月平均实际单价变化p、收费量变化q，则收入增长率为：

g = (1+p)×(1+q)−1 = p+q+p×q。

连续时间的微分近似可以写dR/R=dP/P+dQ/Q，但不能把它直接当较大月变动的精确公式。以下保留原压力假设，统一使用离散算法。

假设情景，不是观测事实	单价月变化p	收费量月变化q	收入月变化g
用量较强	-15%	+20%	+2.00%
中间压力情景	-15%	+10%	-6.50%
用量较弱	-15%	+5%	-10.75%
收入保持不变	-15%	+17.65%	约0.00%

固定-15%降价时，维持收入所需用量增幅为1/0.85−1=17.647%。但本篇没有证据表明所有平台一直处于这个单价和用量组合；公司近期披露的收费扩张，恰好要求撤回“中间情景就是大多数API平台实际处境”的旧断言。

多产品公司的收入应写为各品类P×Q之和，再加订阅和其他收入。廉价模型用量占比提高可能拉低混合单价，同时更长的agent任务增加收费量；缓存提高还会改变价格结构。两个时期的混合单价下降，未必意味着同一服务遭遇同等幅度的价格战。

1.7.3 一笔API账单应该怎样复算

以下是按Fable5.1公开价构造的例题，流量不是实际客户数据：未缓存输入100万token、缓存读取1000万token、输出20万token，则三项费用分别为10美元、2.5美元和10美元，合计22.5美元。若只将缓存读取价换成上一代的1美元、其余条件保持不变，则为30美元，账单下降25%，不是75%。

这张简化账单假设缓存已写入，不含新缓存写入、工具、运行环境、地区加价、税费或协议折扣；真实预算要补齐这些项目，并比较任务成功率。价格低25%而失败重试翻倍，成功任务成本仍可能更高；高价模型一次成功，也可能比低价模型反复调用便宜。

1.8 单位经济与客户ROI：让利润、现金和价值各归各位

1.8.1 应用商的收入与毛利桥

先看一组假设，不把它冒充任何公司的盈利预测：10万个付费用户，每人每月平均实际付款30美元，月收入为300万美元；月推理与托管成本120万美元，另有60万美元交付成本，包括支持、内容许可和支付费用，则毛利120万美元、毛利率40%。这还没有减研发、销售、管理、利息和税，不能叫净利润率。

若推理与托管单价降30%、总用量增20%，这项成本由120万美元变为100.8万美元；收入与其他交付成本暂时不变时，毛利变为139.2万美元、毛利率46.4%。因此上游API价格下降不必导致下游应用毛利下降。若竞争又迫使应用售价降20%，月收入变为240万美元，同样成本下毛利率则仅33.0%。最后结果取决于节约由用户、应用商还是模型商拿走。

1.8.2 客户值不值得付钱

客户月净收益 = 可兑现的新增毛利或成本节约－工具费用－新增集成与复核成本－错误和合规损失。节省时间只有在释放出有效产能、减少加班或产生新增业务时，才进一步转成财务收益，不能直接把员工工资按分钟乘出来全部视作现金节约。

例如，一项假设工作流每月节约20小时，每小时完全成本200元，其中只有40%能够转化为可兑现产能或成本节约，则月收益先计1600元；若工具及复核每月合计1000元，净收益600元。按该例，以“净收益/本期投入1000元”定义的月度简单ROI为60%；若可兑现比例降到20%，收益只有800元，反而净亏200元。这里没有预测哪家企业能做到这个比例，模型只是把真正需要调研的变量暴露出来。

医疗、法律、金融和生产代码不能只优化这道平均数。一项低概率大损失也可能决定产品必须增加人工复核，所以本篇不把任务自动完成率直接视作可替代人员比例。

1.8.3 从毛利走到资本回报

应用企业的预收款可能先增加现金，收入后确认；云企业资本投入先发生，折旧和收入在以后期间展开；模型公司还需要持续训练和研发。比较各层利润时，需要注明研发处理、内容授权、股权薪酬和租赁口径，并检查是否把某公司的投资收益误当经营利润。

原文“每1美元终端消费有0.55美元流向芯片、仅0.10美元留给模型应用”的比例缺少完整抵销表，当前撤回。它把某些企业当期利润率、设备投资及产业链收入切片混在一起，不能支持全球利润分配结论。更可行的办法是选择有账单和合同的单一项目，把终端付款、渠道分成、模型费、云资源费与设备折旧逐项对上，再讨论可复制程度。

1.9 2026年余下阶段与2027年的核验表

不再设“2027年应用ARR必须达到云厂资本开支50%”这种跨口径阈值。年度运行率与年度资本开支不对应相同资产寿命、收入范围或现金流，它们的比值可以提示压力，但不能直接判回本。下面的观察按每家公司下一次正式披露或合同复核滚动进行，不把尚未宣布的日期写成日历事实。

要验证什么	当前可确认	后续需要的证据	什么会迫使我改判断
编程从席位扩展到用量	GitHub已调整计费并披露收入增长	同口径付费留存、单客消费与毛利	用量收入持续增长且留存稳定，应上调固定席位模型之外的空间
企业AI愿付费而非只试用	付费席位和Agentforce ARR已有披露	续费、折扣、范围变化与同口径增长	合同扩张主要来自降价、合并口径或赠额，应下调收入质量判断
对话广告是否可复制	ChatGPT Ads披露1B run-rate	后续实际收入、客户复投与成本	多期增长、复投与产品体验保持，支持新增渠道；只有短期投放则不外推
模型层是否形成可持续利润	收入增长已得到公司披露支持	经审计财务、服务毛利、研发和现金消耗	同口径毛利和现金改善可反驳“收入追不上成本”；未披露不等于亏损扩大
API便宜是否降低成功任务成本	缓存等具体费项下降	固定任务集账单、失败重试和复核	成功任务成本下降同时客户净收益改善，扩大可付费场景
新资产能否回收	云分部仍有真实收入与利润	资产投产批次、利用率和新增自由现金流	新资产回报逐批改善，应收敛资本错配担忧；靠重复融资维持则相反

1.10 我可能错在哪里

我仍可能低估按任务计费带来的市场扩张。若少量高强度企业用户愿意持续购买昂贵但可靠的工作成果，收入可以超出传统开发者席位模型；但也不能把理论能节省的全部劳动成本默认交给工具公司。

我也可能高估私营公司指标的可比性。订阅、用量、渠道收入和合同范围一变，增长曲线就会断口径；即使数字由公司自行披露，也不自动拥有审计报表的证据强度。公开信息暂时不能回答的毛利与现金问题，不能靠精确小数填平。

还有一项与原文相反的风险：我可能低估硬件和推理成本下降、计算效率提高对应用商的帮助。如果单位任务成本下降快于售价，收入不必爆发也可能实现更好的利润；若更可靠的模型减少复核，用户的实际投资回报也会提高。对此不能只看标价，而要同时验证质量、用量和费用。

本篇当前判断是：AI收费渠道已经拓宽，收入增长不应被“价格归零”叙事一笔抹去；资本回报仍要逐家公司、逐批资产核验。研究重点由“有没有人在付钱”，转为“谁付的钱没有重复统计，谁在承担交付成本，谁最终留住现金”。

本版逐项修订记录

分册编号勘误 · 2026-09-08

按本册实际收录顺序重排章节，正文目录、网页锚点和PDF书签由同一正文重建；未收录主题改用报告名称指引，不再假设读者手里有母稿。

全景母稿位置	本册位置
第三部分（3.x）	第一章（1.x）

下列历史修订记录的当前落点已换成本册编号；带“原”“母稿”或描述已删除指引的旧号仍用于追溯。此次只修改编排与定位文字，不重算数据、不改变结论，也不改写冻结记录。

以下保留所选章节的V1.5基础修订记录，并将本轮变更标为V1.5.1；每条对应正文纠错或证据更新。

AI变现与编程TAM：逐项修订

V1.5.1（10月9日），3.2.2：补入OpenAI视觉广告及测量计划；美国测试、合作方案与已实现广告收入分开。

V1.5.1（10月9日），3.7.1：Sonnet缓存价由历史0.20接至0.10美元，新增Haiku按请求分档价目和0.20/1.00美元账单；不把总用量门槛、厂商效果或缓存降幅当作全行业同质量降价。

V1.5.1（10月1日），3.7.1：补Sonnet 5.5与GPT-6.1 Sol价目和固定用量账单；明确任务消耗改善、缓存费下降与标准token牌价不同。新增Microsoft长任务按量收费安排，未将推出计划当成已实现收入或毛利。

V1.5.1（9月24日），3.7.1：新增Sol、Luna及Opus 5.5标准价目和固定token账单算例，区分牌价、厂商任务成本声明及实际单位经济；不从降价直接推利润或需求变化。

1. **章节相关性。** 删除沿用全景版的财报、融资、市场指数和IPO前置更新页；仅将与云收费、广告、订阅、编程及资本回收有关的证据写入对应章节。
2. **收入口径。** 1.1—1.2将“云+广告7500亿美元AI变现”改为分业务、分统计期和分证据的分类表；纠正Azure与智能云部门、年化与全年收入混淆。
3. **新增变现。** 1.2、1.3更新ChatGPT Ads8月31日公司披露，区分1B运行率、累计收入和盈利。
4. **企业订阅。** 1.3、1.5更新Microsoft付费席位和Salesforce8月ARR，单列Agentforce产品范围变化，不将所有增长当作同口径自然增长。
5. **私营公司数据。** 1.3—1.5保留公司公开披露的确切日期；独立复审补入Anthropic5月28日已披露的47B运行率，替换仅停留4月30B的旧锚。更晚媒体估算未获得正式文件者不冒充当前一手事实，删除无依据的统一盈利状态标签。
6. **编程TAM。** 1.4纠正人口出处和十倍单位错误，完整重算价格—渗透率表；保留历史专业人口基数，补充新的总人口线索但不混用。
7. **商业模式与估值。** 1.4写入GitHub按量计费事实，增加内含额度抵销和非开发者季节付费情景；撤回“估值大于年度TAM即不合理”的推论。

8. **生产力证据。** 1.4加入METR原实验与2026年后续限制，撤回无条件效率提升5—10倍，并保留新工具可能改善的反证。
9. **资本回收。** 1.6保留三层结构，撤回未取得原始模型的总量作为当前输入；纠正线性达峰、收入比与IRR混用，改为逐期FCFF与资产批次核验。
10. **API模型。** 1.7用9月实际费率与离散增长式替换“价格归零/死亡螺旋”定论；精确修正悲观情景为-10.75%，以固定账单展示缓存降价的边界。
11. **单位经济。** 1.8增加可复算但明确假设的应用毛利与客户ROI桥；撤回没有抵销表支持的55%/10%产业利润分配。
12. **结论与反证。** 1.9—1.10撤回唯一编程市场、必然收入下降与跨口径回收阈值，改为收费扩张已确认、资本回收待逐项证实；保留双向改变判断的条件。

详细核验网址、修改前缺陷和计算验收见《V1.5_变现正文修订证据》。本篇仅为个人研究，不构成投资建议。

本篇V1.5.1修订记录

1. **费率有效期。** 仅在1.7.1补入Google推广价到期与后续拟适用价格的区别，避免将限期报价外推为长期单位成本。事实来源为对应正文的9/2官方发布及脚注；未加入无关财报前言，未改动旧V1.5修订记录。