大队长 · AI产业周期研究

AGI与国际格局

技术能力、算力与能源、出口规则和国际竞争。

V1.5.1 · 正文修订
2026-10-09

按本篇主题组织证据与分析
个人研究 · 基于公开信息 · 不构成投资建议

免责声明与阅读边界

本报告为“大队长”基于公开资料形成的个人研究，不代表任何任职机构观点，不构成个性化投资建议、收益保证或交易指令。技术和商业判断可能错误，信息也可能随后修订。

V1.5.1为V1.5基础上的增量正文修订版，增量资料检索截止2026年10月9日上午；各项财务、统计、行情与政策数据以正文明确的期间或观察日为准，不能全部理解为该日现值。公司指引、研究假设和已实现结果分开阅读；缺失的原始证据不以推测填补。

本版按主题重编，不沿用旧版分页；旧版与历史档案保留不改。历史评分和预测记录只用于追溯，未完成统计校准的数字不属于经过验证的崩盘概率。审计条目总数不等于本轮全部事实复核通过。

本版修订说明

1. AGI篇：补AMD预发布测试的方法和速度门槛，厂商吞吐比不外推成商业收入或投资回报。

逐项勘误与修订见文末《本版逐项修订记录》，可从目录跳转。

2026-09-08编排勘误：本册正文从第一章起连续编号，目录和当前章节引用同步；导读不占章号。母稿对应关系见文末“分册编号勘误”，研究数据与结论未因本次编排修改。

目录

目录及页码依据本版正文生成；PDF内可点击跳转。

第一章：AGI何时到来？ 4

1.1 实验室的时间表，应怎样读 4

1.2 Scaling：从“算得更多”转向“交付同一结果花多少代价” 4

1.3 AGI定义：能力、通用性与自主性不能互相替代 5

1.4 算力、电力和数据，怎样约束而非决定时间表 6

1.5 从技术时间表到估值：保留折现，撤回伪精确归因 7

1.6 我可能错在哪里 8

第二章：AI如何颠覆国际格局？ 8

2.1 中美模型差距：先修正量尺，再讨论追赶 8

2.2 主权AI：比较实际能力，而不是把公告金额相加 9

2.3 军事与安全：采购需求、可部署能力和实战效果三层证据 9

2.4 就业冲击：更新到8月研究，保留因果边界 10

2.5 能源格局：采用IEA 2026更新，区分需求与投资回报 10

2.6 从货币到制度：国家议价力来自什么 11

2.7 模型与硬件：两条曲线保留为可检验框架 12

2.8 出口管制：更新法律和商业事实，不把传闻写成规则 13

2.9 我可能错在哪里 14

本版逐项修订记录 15

分册编号勘误 · 2026-09-08 15

AGI与国际格局：逐项修订 15

第一章：AGI何时到来？

9月初的新模型，使“能力还没有进步”越来越难成为谨慎定价的理由。Anthropic 在9月1日发布 Fable 5.1 与 Mythos 5.1，Google 在9月2日发布 Gemini 3.8 Flash 与 Flash Cyber，OpenAI 在9月3日发布 GPT-6 Astra；这些产品既拓展长流程任务，也呈现不同的部署限制。对本报告而言，需要重估的是从任务能力到经济产出的传导速度，而不是因为过去担心泡沫，就维持一个必然推迟的 AGI 时间表。Anthropic 发布说明、Google 发布说明、OpenAI 发布说明

我仍然把能力、交付和回报分开。模型在某类测试中跨过人类参照线，是技术证据；企业敢不敢交给它连续执行真实业务，要加上可靠性、权限、数据和责任；能力创造的收益最终由模型厂商、应用商、员工还是客户取得，则是另一个竞争问题。此前正文把这几层压成了一个 AGI 年份，又让这个年份承担估值和崩盘时间的解释，证据承受不了这样的推导。

1.1 实验室的时间表，应怎样读

公开预测的价值，在于暴露预测者对技术路径的假设。它不是一组口径一致的测量值。有人讨论能否完成多数高价值工作，有人要求跨领域学习达到人类水平，还有人谈的是远超专家群体的超级智能；把这些年份排在一起取中位数，得到的只是一个数字，并没有得到共同定义下的概率。

Dario Amodei 在2026年1月《The Adolescence of Technology》中继续讨论短时间内出现强大 AI 的可能，并保留时间可能更远的限定。他设想的是具备广泛专业能力、可大规模复制的系统，不只是一个聊天产品升级。本文把它作为实验室负责人提出的风险情景，不作为“2027年已经得到确认”的事实。其商业利益需要识别，技术论证也不能仅因商业利益就被忽略。Amodei 原文

另一种更便于研究的进展，是 Google DeepMind 2026年3月16日公布的认知评估框架：把一般认知能力拆成十类，并要求用有保留测试、有人类参照的任务形成能力画像。这一方法没有解决所有定义争议，却比“某位负责人说还差几年”更适合持续更新，因为可以明确看到某一能力改善、另一能力仍薄弱。DeepMind 认知框架

因此，本版撤下 Altman、Hassabis、Musk、LeCun、Sutskever、Hinton、Schmidt 等人在不同场合的年份汇总，不沿用未经逐条找到原始访谈和发布日期的精确概率，也不再用“技术最深”“最独立”给人物打分。这不表示这些人的意见不重要，而是本篇尚未完成那张表所需要的同口径核验。

预测市场也遵守同一纪律。要保留一个数字，至少要同时存下问题的结算条件、截止日期、观察时点和聚合方式；“通用智能首次宣布”“多数职业自动化”“超级智能”不能互相替代。旧文中的 Metaculus 2033年、Manifold 35%、Polymarket 25%等，不具备可重放的同期快照，本版不把它们写作当前市场共识，更不称为“最客观参考”。

本篇的时间判断改为：能力继续快速改善有证据，通用性和经济替代程度仍须分别验收；暂不提供统一 AGI 到达年份或经校准概率。 一个可用的时间判断，必须先说明什么算到达，以及什么新证据会使判断前移或后移。

1.2 Scaling：从“算得更多”转向“交付同一结果花多少代价”

预训练、后训练、推理时计算和外部工具共同改变系统能力，不能用其中一代模型的表现宣告整条路径结束。旧文把 GPT-4.5 的媒体评价当作预训练缩放失效的证明，又把推理模型概括成“思考越久越好”，两端都说得太满。预算增加后，某些任务会改善，某些任务可能更早到达收益平台；若增加搜索只是反复走入错误路径，更多计算并不自动变成更可靠的答案。

评估应固定任务、工具和质量门槛，再比较成本，而不是只比每百万 token 的价目表。一项业务的有效成本至少包含模型调用、重试、工具调用、基础设施、人工复核和失败返工。模型 A 单次调用更便宜，若需要多次尝试和大量人工检查，交付一个合格结果未必便宜；模型 B 单次更贵，但能减少流程往返，也可能更有经济性。这是本篇的研究方法，不是对任何厂商成本的实测结论。

9月的公开评测提供了一个具体例子。同一模型发布页上的高分项目和低分项目并存，不能挑最醒目的一个分数代表全部能力。下表仅记录当次发布披露，不制作跨年份“智能总量”曲线。

当次披露	可核结果及条件	应怎样使用
OpenAI GPT-6 Astra，9月3日	FrontierMath Tier 4（v2）97.6%；AutomationBench 41.4%；发布页注明各推理预算中的最高结果，研究/API环境可能不同于产品环境	专门数学测试与业务流程测试进展不均，不能用前者代替后者
Anthropic Fable 5.1，9月1日	OSWorld 2.0 部分计分77.9%、严格计分41.7%；HLE无工具60.9%、有工具65.0%，且有生产防护参与	同一模型换验收规则或工具，结论会明显变化；不能与其他设置的分数直接排行

来源：OpenAI 评测表及脚注、Anthropic 评测表及防护说明。这些是厂商披露，不是本文完成的独立复测。

旧版 SWE-bench、HLE、ARC-AGI、GPQA、FrontierMath 的进展表把不同版本和预算连成一条曲线，本版撤掉那条伪可比曲线。此后若恢复趋势图，每个观测点都应绑定模型版本、数据集版本、工具、尝试次数、预算和测试日期；只要关键设置变化，就应另开序列，而不是继续画线。

长任务能力的进展也需要这样读。METR 的50%时间跨度，是根据人类完成任务所需时间拟合出的成功率尺度，不是“AI已能稳定独立工作这么久”。METR 在2026年3月20日说明，修正拟合错误会改变既有结果，任务分布与统计选择也会显著影响估计。原文直接写“14小时自主工作”，遗漏了可靠性阈值和样本范围，本版撤回这种表述。METR 方法与修订

对 DeepSeek 的讨论回到已公开产品与技术材料。官方透明中心列明 DeepSeek-V4 于2026年4月24日发布，提供模型卡和技术报告入口；此前“R2、32B、AIME 92.7%、单24GB显卡”组合仍缺一手依据，不能继续作为低成本突破的论据。API报价也不等于训练成本，低报价可能包含效率改善、补贴或商业选择，只有完整成本口径才能区分。DeepSeek 官方透明中心

我的判断是：**竞争正在从一次回答的能力，延伸到一项工作能否在可接受的预算和风险内结束。** 如果高分没有减少人工检查，企业支付的对象仍然是辅助工具；若任务验收率提高、复核成本下降且能持续复现，应用收入的扩张才有更扎实的基础。

9月22日，OpenAI发布Sol与Luna，Anthropic发布Opus 5.5，竞争继续向不同能力与成本层级展开。Anthropic称Opus 5.5典型工作成本比Opus 5低40%，但其中包含标价与任务耗用量变化；这一厂商声明需用固定任务和验收标准复测，不能直接推出企业人员成本下降40%。这些产品扩大了可选的部署方案，仍没有给出统一AGI到达日期。OpenAI官方变更记录、Anthropic发布说明

1.3 AGI定义：能力、通用性与自主性不能互相替代

本文保留三类讨论，但不把它们当作已排好先后的三个到达日期。

讨论对象	真正需要回答的问题	不足以单独证明它的证据
经济上有用的强 AI	在什么行业、质量和总成本条件下，能够完成多少付费工作?	竞赛高分、用户数、单次演示

讨论对象	真正需要回答的问题	不足以单独证明它的证据
广泛的人类水平认知能力	在未专门准备的新任务上，学习、推理、记忆和迁移是否足够稳定？	少数任务超人、长上下文长度、模型自己声称理解
超级智能与高度自主系统	在广泛领域能超越多强的人类参照，且可以多大范围独立行动？	更快回答、更多并行实例、某项安全阈值被触发

DeepMind 2023年的“Levels of AGI”把表现深度、能力广度与自主性区分开来；2026年6月12日“From AGI to ASI”继续讨论 AGI 之后的多种发展路径，而不是给出一个从当前模型直接通向超级智能的保证。本文采用这一区分，但表中的经济验收问题属于作者用于产业研究的操作化方法。AGI 层级论文、DeepMind 后AGI研究

安全限制也不能简单当作能力不足。模型可能具备一项潜在能力，但部署方因为风险而限制访问；反过来，移除防护后的研究成绩，也不能等同于客户可购买的生产能力。OpenAI 9月3日称 Astra 达到其内部准备度框架的网络安全 Critical 等级，同时披露监控难度与额外部署防护。这是厂商风险分类及测试结果，并非跨机构共同认可的 AGI 认证，也不能推成现实世界普遍失控已经发生。OpenAI 安全说明

Google 的同次发布提供了另一种对照：3.8 Flash与Flash Cyber使用同一基础智能，但网络安全防护和开放对象不同。前者进入API、企业及订阅产品，后者因网络安全限制更宽松，仅通过Fairwind计划提供给可信防御方。这个差异提醒我们，评估客户实际可用的能力，必须连同产品版本、权限和防护配置记录，不能把受限环境的成绩全部折算为普通客户能够购买的服务。Google部署与防护说明

投资研究需要同时保留这两种方向：能力变强可能拓宽收入来源，防护、审批、责任和数据隔离也可能增加交付成本。把产品受限全部解释成“模型不行”，或把实验室上限全部折算成即期收入，都会误读商业化速度。

1.4 算力、电力和数据，怎样约束而非决定时间表

原文说 AGI 时间“本质上是前沿训练边际算力的函数”，低估了算法、数据、评估方式和组织能力。算力是重要投入，但投入扩张和能力进展之间没有一张经验证的 AGI 年份换算表；同样的硬件规模，可以因利用率、通信、故障和训练方案不同而产出不同结果。

安全工程也会改变训练进度。OpenAI9月1日说明，在此前Hugging Face事件后，曾暂停部分前沿训练两周，其中包含部分Astra训练；某些更大的强化学习运行暂停更久，8月28日已恢复此前暂停的一项大型运行，部分小规模实验仍暂缓。公司同时明确Astra没有参与原事件。这是特定训练流程的暂停与恢复，不能写成所有训练停摆，也不能据此推算AGI统一延期；它说明硬件就绪之后，隔离、监控和安全验收仍可能约束有效研发进度。OpenAI训练与恢复说明

先看能够运行的集群，而不是宣布的功率。 一处站点的公告可能分别提到土地容量、获批供电、已通电容量、已安装服务器及正在提供服务的能力。它们不是五种说法指向同一个数量。原文据规划功率推算2027年前有效训练算力仅能扩张8—12倍，缺少项目清单、投运节奏和利用率，不能保留为事实。

电力约束是地方性的，也会被重新分配。 数据中心关心的不只是全国发电量，还有特定节点的变压器、输电、备用电源、许可和可用时间。发电项目排队接入电网的统计，不能直接套给所有新增用电负荷；自备电源也有设备、燃料和监管约束，并非天然快捷通道。第二章用 IEA 更新说明需求规模，本节只保留机制：某个地点延误，可能带来迁址、降密度、分期投运或推迟交付，不能直接宣布全球技术路线因此延后若干年。

先进制造约束要穿透到系统交付。 先进制程、HBM高带宽存储器、先进封装、网络设备和整机集成都可能限制数量，但“封装晶圆/月”不能直接换算成“每年几座训练中心”。需要知道晶圆尺寸、产品组合、良率、每个封装所需资源、芯片互联方式及单站配置。原文 CoWoS 产能支持5—8座集群、供需缺口2—3倍、制程复制固定需要三年的说法，未能给出这条计算链，本版撤出。

数据约束应按任务讨论。 高质量、新颖、可合法使用的数据更有价值，不等于互联网文本已全部用完。可自动验证的数学或代码任务，与依靠现实反馈、隐性知识和复杂评价的任务，获得可靠训练信号的难度不同；合成数据能扩展某些训练，也需要筛选与独立检验。对于未披露训练集的模型，本文不再猜测它“已经消耗了公开数据的30—50%”。

下表替代原来的“算力倍数—AGI年份”表。它是一组研究情景，不分配概率，也不声称可以预测某年到达。

情景	需要观察到的变化	研究含义	使该情景失效的证据
能力与部署共同加速	新任务稳定通过，单位合格任务成本下降，客户从试点扩为持续使用	应提高商业化速度假设，复查过度保守的采用率	成绩只在特定工具或高预算下成立，客户留存和验收未改善
能力改善、交付受阻	评测提高，但接入、数据治理、责任或供应交付持续拖延	延后受影响业务现金流，保留其他已可用场景收入	客户在同等合规要求下快速规模部署
成本改善、价值被竞争让渡	替代模型多、降价快，客户获得明显收益而厂商利润率承压	区分产业生产率提高与模型供应商的投资回报	产品差异和迁移成本使净价格、续约及利润率保持稳定

这张表留下的开放问题很具体：下一次能力跃迁，能否让需要反复人工复核的任务真正减少复核？新建算力是先满足增长的付费需求，还是先成为固定成本？这比保留一个看似精确的 AGI 年份更值得跟踪。

1.5 从技术时间表到估值：保留折现，撤回伪精确归因

AI 公司的现金流可以来自广告效率、云服务、代码工具和企业自动化，不必等到所有人都承认 AGI 已经到达。因此，原文“如果AGI不来，当前估值无法用任何模型证成”不成立；相反，某些远期估值确实可能依赖尚未验证的大规模采用，必须通过公司模型识别，不能先给整个行业统一贴上一个比例。

本版撤回“AGI贡献估值40—60%”“推迟三年通常打折40—55%”及某家实验室估值必然从5000亿美元降到2000—2500亿美元的表述。没有现有业务、未来业务、资本投入和融资条款的拆分，就无法从一个融资估值倒推出 AGI 叙事占比；私募不同轮次的权利条款也会影响表面估值的可比性。

可以保留的是一个透明的折现计算。假设某一段原本会产生的现金流**整体后移三年，金额与风险不变**，它的新旧现值比为 `1 / (1+r)^3` 。这不是任何公司的目标价，也没有纳入额外投入或业务流失。

年折现率 r（情景输入）	该段现金流后移三年的现值保留比例	该段现值减少
8%	79.4%	20.6%
10%	75.1%	24.9%
12%	71.2%	28.8%

如果仅有40%的企业价值来自这段被延后的现金流，那么在10%折现率这一简化情景下，企业价值的纯时间损失为 `40% × [1 − 1/(1.1)^3] ≈ 9.95%` ，不是24.9%，更不是自动变成40—55%。40%只是演示输入，不能反向称为市场已经给 AGI 分配了40%的价值。

竞争可能进一步降低远期净价格，新增训练或服务支出可能减少净现金流，融资可能稀释普通股权益；这些因素都需要进入对应年度的模型，而不是在纯折现损失之上再随意加一个折价。需求超预期、成本下降或者其他业务改善，也可能部分抵消延期损失。方向必须由模型输入决定。

能力到现金流确有时滞，但“所有企业需要18—24个月采购”“AGI后必有2—4年空窗”缺少统一样本，不再给出这种固定时滞。应逐场景看付费试点、扩容、续约、合同责任和回款：开发工具的用户可能当天尝试，金融核心流程则可能经过数据权限、审计和多层验收。把两者放进同一个采用率，会高估某些业务，也低估另一些业务。

同理，电力和半导体资产不因 AGI 推迟就天然安全。有明确客户、可执行长约和可承受债务的项目，与依靠未来租约填满的投机性扩建，风险截然不同。能源或设备需求增加，最终还要经过竞争、定价、资本开支和营运资金才到股东回报。本文保留对兑现时间和资本错配的警惕，不提供一个只凭 AGI 判断即可成立的对冲组合。

1.6 我可能错在哪里

第一，9月的新模型可能正处于企业采用加速的早期，既有收入与就业数据天然滞后。如果多家客户持续披露同类业务的验收率、人员投入和净收益改善，只用历史落地慢来压低采用率，会低估这一轮变化。

第二，过度强调榜单限制，也可能漏掉真实技术跃迁。标准化评测不是全部，但也不是没有价值；应保留可复现进步，同时用新任务、不同预算和实际交付补充，而不是因为结果与原判断冲突就否定评测。

第三，物理瓶颈和数据瓶颈会随着架构、调度与算法变化而移动。如果同等质量的工作需要明显更少的计算，旧产能可能获得更多产出；若更便宜的能力诱发更多调用，绝对需求又可能上升。不能只选择有利于看多或看空的一半机制。

最后，本篇没有完成 AGI 概率校准，也没有把全部前沿模型放进同一个独立测试。保留缺口意味着暂时少说一个数字，不意味着可以停止研究；下一次修订需要优先补真实工作样本，而不是再添一张名人预测时间表。

第二章：AI如何颠覆国际格局？

中美模型的竞争不等于两国完整产业能力已经相同，芯片受限也不等于受限的一方无法做出有价值的应用。AI 对国际格局的影响，要沿着模型、制造、能源、资本、制度和应用扩散分别观察；其中一层收敛，另一层完全可能仍受约束。原文把“模型差距2.7%”与“中国市场归零”并列为总判断，既混淆了测量口径，也把国家竞争压成了单向叙事。

2.1 中美模型差距：先修正量尺，再讨论追赶

本版明确撤销“从15%缩到2.7%的能力差距”。Arena 的配对偏好和 Bradley–Terry 类评分反映特定样本中哪种回答更常被选中，分数原点和尺度不提供“智能相差百分之几”的意义；将30分除以某个总分，不能得到30分所代表的能力比例。即使榜单采用不同评分实现，这条“相对评分不等于能力比率”的限制仍然成立。Arena 评分方法说明

Stanford《2026 AI Index》确实认为中美前沿模型表现差距大幅收窄。这支持“竞争更接近”的方向，但报告有统计截点，不能当成9月8日所有模型、所有任务的实时排名，也不能推出成本、长任务、安全和商业化能力全面一致。本版保留收窄判断，不继承错误的百分比解释。Stanford 2026 AI Index

要形成一张对投资有用的比较表，我会同时记录任务正确率、同质量成本、响应时延、中文及专业数据适配、部署权限、工具调用和失败恢复。中国模型在中文应用和本地部署上可能更符合某些客户需要，美国模型在另一些复杂任务上可能有优势；两者都应在目标场景里验证，而不是用国别替代模型版本和工作负载。

DeepSeek-V4 的官方发布和华为云2026年4月24日首发适配说明，能够核实模型与国产平台服务适配的进展。这是有意义的工程证据，但模型可在某平台运行，不等于它全部训练阶段都在该平台完成，更不等于所有企业迁移成本已经消失。本版不再从推理适配外推完整前沿训练的自主供给。DeepSeek 官方透明中心、华为云首发适配

2.2 主权AI：比较实际能力，而不是把公告金额相加

主权 AI 的合理诉求包括数据治理、关键服务连续性、本地语言、产业能力和政策自主。买到外国芯片、租到海外模型与拥有本地长期运维能力，满足的是不同层次的需要；国有资本参与也不自动等于项目具有商业回报。

美国：把 Stargate 的承诺与运行分开。 OpenAI 2026年1月20日官方更新称，Abilene 已在训练和服务前沿系统，同时把2029年10GW目标及超过半程的数量明确称为规划容量。已经提供服务是比签约更强的证据，却不能据此宣布整个10GW都已投运。多年投资目标、各站点预算和供应商合同可能指向同一项目，不应重复加总。Stargate 官方进展

沙特：首期、五年规划与当地吸收能力不同。 NVIDIA 与 HUMAIN 2025年5月13日公告的范围是未来五年最高500MW、数十万颗GPU的规划，首期为18,000颗GB300系统；这不能写成“已采购50万颗GPU”。芯片到货以后，还要解决机房、电力、网络、运维与客户需求，才形成可出售的计算服务。本轮仍未取得各期验收与利用率的连续一手记录，因此不把旧规划升级成2026年9月15日已验证投运规模。NVIDIA—HUMAIN 公告

欧洲：动员投资不是财政已经支出。 欧盟 InvestAI 的2000亿欧元目标包括动员公共和私人资本，其中200亿欧元用于巨型AI设施的安排也不等于全部资金已拨付。欧委会的具体设施页面强调以欧盟、成员国与金融机构资金降低风险、吸引私营投资。研究时要继续跟踪项目遴选、融资关闭、建设和使用，不把政策目标直接放进年度设备收入。欧盟AI行动计划、欧委会AI Gigafactories

印度：区分已供给与拟增购。 印度政府2026年2月17日披露现有38,000颗GPU，并宣布随后增加20,000颗；同一声明中的未来两年超过2000亿美元投资，是预期而不是到账记录。本文保留这些数值的公告日期，不把38,000与20,000相加后称为9月已验证运行的58,000颗。印度PIB公告

中国：应用扩散需要比装机更细的验收。 国家发展改革委2025年8月26日对国务院“人工智能+”意见的解读，把科学、产业、消费、民生、治理和全球合作列为重点，并强调应用与基础能力供给协同。政策目标应与实际采用分开；也不能从安全可控要求推出所有国资云和政务云拥有同一个全国强制国产比例。国家发展改革委政策解读

英国、日本及阿联酋等地仍是重要观察对象，但本次没有逐个复核其全部项目进度，不再给出缺少边界的“全球主权AI总投入”排名。对这些项目，后续应统一收集投运容量、可用时间、单位成本、外部客户收入和对单一海外供应商的依赖；把地区间可比较的指标补齐，比把各种意向金额汇总成一个更大的数字更有价值。

2.3 军事与安全：采购需求、可部署能力和实战效果三层证据

AI 的军用价值不能靠公司估值证明，估值也不能用每一份政府合同总额直接解释。美国国防部2025年5月21日公布 Palantir Maven Smart System 软件许可合同的7.95亿美元修改金额，是可核的采购记录；它不是当年已确认收入，更不提供模型在某次行动中的效果测量。美国国防部合同公告

本版撤下 Anduril、Helsing、Shield AI、Scale AI 等企业的旧私募估值列表，以及“伊朗行动期token上涨4425%”对实效的暗示。资金、调用次数和可交付能力之间没有固定换算关系；如果没有原始合同条款、客户验收和可公开验证的任务结果，不能写成军事 AI 已全面规模化成熟。

从产业研究角度，可以按证据强度逐步推进：先核正式预算和采购，再核可部署范围、权限与责任，最后才讨论持续服务收入、毛利和续约。某项实验、演习或厂商演示能够说明技术方向，但不能越级成为实战效果的证据。军工客户还可能要求专有集成、离线环境和长周期认证，这些成本不能被“软件毛利率高”的一般印象遮住。

前沿模型的网络安全能力使这一问题更紧迫，但安全发布材料主要说明受控测试和防护边界，不应被用来渲染未经证实的作战能力。对投资者，更可核的影响是客户安全预算、产品可用范围和部署责任怎样变化，而不是凭一次演示押注全部军事格局已经重写。

2.4 就业冲击：更新到8月研究，保留因果边界

本节最重要的新证据来自 Stanford Digital Economy Lab 2026年8月修订的“Canaries in the Coal Mine?”。作者报告：在其分析中，22—25岁、从事AI高暴露职业的年轻人，就业相对较低暴露同龄人的参照路径落后19%；分化主要通过招聘减少而非离职增加体现。同时，研究没有发现全经济范围的普遍岗位替代，作者把这些结果定位为描述性早期信号，不是AI造成失业的因果估计。Stanford 修订研究

原文“0—2年经验程序员就业下降20%，资深程序员上升”的写法，把年龄、职业、比较期与对照组混在了一起，也错误挂在 Anthropic 使用报告之下。年龄不等于工作年限，高暴露职业不只包括程序员，相对参照路径的落后不等于绝对岗位同比下降19%。此外，教育控制、样本选择和部分既有趋势都会影响解释，不能省略这些限制后宣称AI已经消灭了对应比例的岗位。

Anthropic Economic Index 更适合回答用户把什么任务交给模型、如何使用，而不是用来计算全国就业变化。2026年3月24日发布的“Learning curves”研究观察的是2月Claude使用，用户自选样本不等于全部劳动者或企业。使用量上升既可能是自动化，也可能是增强工作，两者对招聘和产出的影响不同。Anthropic 研究与样本说明

IMF此前关于发达经济体约60%岗位可能受AI影响的结论，讨论的是暴露和互补/替代潜力，不是60%岗位消失。其2026年1月的新技能研究继续把劳动市场变化拆为技能需求、工资和机会差异，提示单一失业总量并不能概括转型。IMF 暴露度原文、IMF 2026技能研究

这会怎样进入国际竞争分析？如果入门任务减少而资深人员产出提高，短期生产率和长期人才培养可能朝相反方向走；企业节省的成本，也未必全部转成利润，可能通过降价交给客户。应跟踪招聘结构、岗位职责、单位产出、工资和培训，而不是仅盯一份裁员名单。中国、印度和美国在服务出口、产业结构和人才路径上不同，不能把美国某一年龄组样本直接外推成全球就业预测。

本篇据此提高对年轻劳动者入门机会和组织培养机制的关注，但没有把该研究升级为“AI已经引发宏观衰退”，也没有给出净失业人数预测。

2.5 能源格局：采用IEA 2026更新，区分需求与投资回报

IEA 2026年4月16日《Key Questions on Energy and AI》把全球数据中心用电估计更新为2025年485TWh，并在其中心预测中给出2030年约950TWh、约占届时全球用电3%；其中AI导向数据中心用电预计增长更快。这里的485和950均是**全部数据中心**口径，2030数字是预测，不是已经发生的需求。IEA 2026更新

旧版2025年报告的2024年415TWh、2030年945TWh可以用于说明预测沿革，不能与新基年混成一条实际增长序列。原文“2026年超过1050TWh”“2030年AI占美国用电8—12%”“2025美国电力增量50%”涉及不同研究、地域和数据中心范围，未完成同口径核查，本版不再使用。IEA 2025版

比较项	旧研究版本	本版采用	可得出的结论
全球数据中心基年用电	2024年415TWh	2025年485TWh，IEA2026年估计	基年向前推进一年，不能称为原年数值被上修
全球数据中心2030年用电	2025版预测945TWh	2026版预测950TWh	中心预测接近；不能据此说全部近期瓶颈已经解决

用电增长首先改变的是地区负荷结构。对于已有稳定低成本电源、网络和变压器余量的地区，新增负荷可能提高现有资产利用率；对于本已紧张的地区，新增负荷则需要扩建，建设成本由谁承担、能否收回，会成为居民、监管机构、开发商与公用事业公司的分配问题。因此，“需求更大”与“现有股东赚得更多”之间，还隔着电价机制和资本成本。

核电重启是一个可核的案例，但仍要区分融资与投运。美国能源部2025年11月18日宣布为835MW的 Crane Clean Energy Center 重启项目提供10亿美元贷款；贷款协议完成交割并不代表机组已经重启，更不能从单一项目推算美国2030年前会新增25GW核电。后续应查许可、施工、试验和实际发电，而不是把长期购电协议当成当期电源。美国能源部项目公告

中东的能源和资本、北欧部分地区的电源与气候、中国东西部的负荷和能源互补，都可能影响选址，但低电价不是完整竞争力。训练、推理与实时交互对延迟要求不同，电费优势可能被数据跨境、网络、人才、设备和低利用率抵消。我们需要的是可用、稳定、合规且有客户的计算服务，不是孤立比较一度电的价格。

我保留“能源与电网是重要约束”的判断，撤销“能源是全行业最确定受益方”的表述。能够锁定优质客户、合理分担扩建成本且不承担过量闲置风险的企业，更可能把新增需求变成回报；若项目依赖高利用率才能覆盖债务，而客户仍处于试用阶段，技术乐观反而可能放大财务风险。

2.6 从货币到制度：国家议价力来自什么

先进计算资源可以影响谈判，但它不是字面意义上的硬通货。芯片有迭代、故障和使用场景，计算服务有时效和地域限制，无法像统一货币那样直接互换。原文从 Stargate 使用美元结算就推出美元体系强化，跨过了贸易、储备、资产供给和资本流动等必要环节，本版不再保留这一直接因果。

更值得研究的是控制权落在哪里：模型接口能否被单方面关闭，数据与日志由谁处理，软件更新依赖谁，芯片与备件是否持续可得，关键岗位由本地团队还是外部供应商运行。主权基金可以买股份，也可以买服务或建基础设施，三种行为的现金流、稀释、控制权和政治目标并不一样，不能合并成一个“主权资金托底”的利好。

规则本身也是竞争因素。欧委会2026年7月31日说明，8月2日起开始相关执法及新的透明度要求，包括部分系统告知用户正与AI交互、特定合成内容标识。这些是已进入实施阶段的事项，不再只是未来日历；也不能把这一日期写成所有高风险系统义务在同一天全部生效。欧委会7月31日说明

对供应商，这类要求可能增加标识、日志、评估和客户支持成本，也可能让已具备合规能力的企业获得采购信任。究竟形成壁垒还是压缩利润，要看新增成本、可执行的统一标准和客户是否愿意支付，不能预先假定“监管强就必然落后”或“监管强就必然拥有定价权”。具体法律适用仍需按产品、主体及正式文本另行判断，本文不是合规意见。

先进制造的地域集中同样有双重性：既能形成议价力，也使供应中断的影响更集中。所谓“硅盾”不是可以直接代入估值的安全保证，应通过供应商、产能地区、备份能力和关键交付期分析风险。技术地位重要，并不意味着地缘风险已经被技术地位抵消。

2.7 模型与硬件：两条曲线保留为可检验框架

9月28—29日Sonnet 5.5和GPT-6.1 Sol继续降低部分工作流的用量或缓存费用，但能力提高、任务成本下降与企业回报仍是三道验证。厂商测试及公开价目支持预算重算，不支持提前给出统一AGI年份或行业利润率。Sonnet 5.5发布、GPT-6.1 Sol发布

旧版认为“模型收敛、训练硬件分化、推理硬件收窄”，这个区分仍有研究价值，但本版不再把它称为已经量化确认的结构性事实。模型能力、训练集群效率和推理部署成本之间有联系，却没有一一对应关系，需要独立测量。

前沿训练关注的是系统效率。 单颗芯片的理论浮点算力只是输入之一。大规模训练还取决于存储带宽、互联、通信算法、编译器、容错、调度、有效利用率与整轮训练能否完成。把某国产芯片说成“H100的70%”，若不说明精度、模型、并行规模、软件栈和功耗，就不足以形成采购或产业判断；用这个百分比再推国家落后几代，更不可靠。

推理关注的是目标工作负载。 固定模型、上下文、输出质量和延迟后，比较吞吐、每个合格任务成本和运维投入，才可能判断国产设备在哪些场景具有竞争力。短文本批处理、长上下文检索、低延迟对话和复杂多轮代理，对算力、带宽与存储的要求不同，不能从某一种任务成功迁移推出整个推理市场已完成替代。

后训练进展不能冒充预训练已全面替代。 适配、微调、全参数后训练、完整预训练的计算规模和目标不同。原版本已提醒910C后训练与完整预训练的边界，本次继续保持这一边界；具体科研结果若没有原始论文、配置和独立复现，就不再往前补猜厂商的整套训练来源。

研究层	验收时应取的证据	仍不可直接推出
模型	同任务质量、预算、版本和独立复测	国家综合AI实力相同
前沿训练硬件	训练日志、集群规模、利用率、故障与实际成本	单卡理论算力等于整集群效率
推理硬件	指定服务质量下的吞吐、延迟、能耗和迁移成本	一个适配案例覆盖全部企业
产业兑现	交付、客户验收、复购、回款及利润	出货规划等于收入或利润

国产替代可能提供订单机会，但并非所有环节都能同时获得高利润。下游替代加速时，上游设备、存储或关键材料也可能遭遇限制；进口产品重新进入时，本地客户可能受益而本地供应商面临压价。旧版35%、50%替代率和40—60%空间缺少统一分母与一手来源，本版撤销，不用更大的预测数字替代实证。

开放生态的入口也在变化，但交易状态必须说清。 NVIDIA于9月2日签署收购Hugging Face的协议，9月3日向SEC提交披露，预期在2027年上半年完成，仍须监管批准及满足交割条件。因此，截至本版只能称“已签约”，不能称“已完成收购”。研究意义在于芯片平台与模型、数据集分发入口可能联系更紧；这属于对竞争结构的判断，不是已经实现的排他控制。交易8-K、SEC披露日期

NVIDIA承诺继续支持开放模型和数据集，并保留用户对云、框架及不同硬件的选择，不要求使用NVIDIA算力。这是收购方的公开承诺，后续仍须验证平台治理和实际兼容性，不能由承诺推定开放性永久不变，也不能反过来断言中国模型会被自动排除。对国际竞争，值得跟踪的是跨芯片分发、模型可得性和监管适用怎样变化，而不只是交易规模。NVIDIA开放生态说明

本篇的保留判断是：**中国模型和应用有参与全球竞争的基础，硬件约束须按训练、推理和具体供应环节拆开；研究公司时，最终仍要核客户愿意为哪种可交付能力付多少钱。**

9月16日的MLPerf Inference v6.1提供了一组预览证据：NVIDIA披露Vera Rubin NVL72在Qwen3-VL和DeepSeek-R1上的吞吐最高分别达到GB300的3.7倍和2.5倍，软件栈及负载不同。MLCommons次日分析确认Preview类别；本文未独立复跑，不能把测试倍数当收入或利润倍数。NVIDIA测试说明、MLCommons方法与分析

9月30日证据已从预览推进到有限生产使用：CoreWeave称Rubin NVL72向指定客户有限提供，涉及数百颗GPU，Cognition是首个生产客户；其SWE-2推理在相同交互性能条件下，每GPU总token吞吐最高达到GB200 NVL72的4.8倍。这是客户测试、供应商发布，不是本报告独立验收；与前述不同模型、GB300基准的MLPerf不能拼成同一增长序列。设备小时成本及实际利用率尚缺，不能直接把单位成本除以4.8。CoreWeave工程说明

NVIDIA同日称CoreWeave的V100仍在运行客户工作负载，反驳了“每次换代旧卡就立即无用途”的极端说法，却没有给出租价、余下成本或项目回收率。仍在使用不等于租金不降，也不等于所有旧卡投资已经回本。NVIDIA生产部署说明

对资本回收，效率改善有两面：同样设备投入可能支持更多收费任务，也可能降低旧设备的可承受租价。只有利用率、任务需求、功耗和实际采购成本进入同一模型，才能判断哪一面更强；不能将基准吞吐改善直接换算成全行业算力需求减少。

AMD于10月8日补充解释MI455X相对MI355X的测试：在DeepSeek-V4-Flash、输入输出各1,024 token的单GPU比较中，每用户20 token/秒门槛下总吞吐比为2.47倍，90 token/秒门槛下才达到33.98倍。测试来自AMD于7月使用预发布硬件与软件的厂商测量，不是10月交付验收，也不是对NVIDIA的比较。工作负载和交互门槛一变，倍数随之改变，不能把最高点直接除进全行业推理成本或转成投资回报。AMD技术说明及测试脚注

2.8 出口管制：更新法律和商业事实，不把传闻写成规则

第一处必须纠正的是时间。美国 BIS 在2025年5月13日宣布撤销拜登政府的 AI Diffusion Rule，并指示不执行该规则；因此，原文将那套全球三层安排继续列作2026年现行总框架不妥。它与2026年某份新草案的媒体消息是不同事件，不应混成“同一规则在2026年才被撤回”。不执行该规则也不等于其他先进计算、最终用途和实体限制一并取消。BIS 2025年公告

第二处是2026年1月13日已公布的调整。BIS 对 NVIDIA H200、AMD MI325X 及类似芯片向中国出口的申请改为在安全条件下逐案审查，并提出美国供给、买方合规和第三方检测等要求。这不是全面自由出口，也不是所有买方都已获许可。BIS 2026年1月13日公告

还要补上2026年5月31日的BIS指引：对于总部或最终母公司总部位于D:5国家组或澳门的主体，即使实体设在其他境外地区，出口属于该指引范围的先进计算物项仍须申请许可，除非适用规定的许可例外。该要求源自2023年，不能把2025年不执行AI Diffusion新增要求理解成一并取消。研究海外供给时，要同时核最终母公司、物项与具体许可，不能只看机房所在地。BIS 5月31日正式指引

同一指引也保留存量运行边界：其他活动符合EAR的正常数据中心运营商，在进一步通知前，无须仅因此停止现有物项的使用、存储、处置或维护。它并不是要求所有境外存量机房停运的新禁令，不能省略这项限定后推算全面断供的规模。BIS指引末段

商业落地还需另核。NVIDIA 截至2026年7月26日季度的10-Q说明，美方已给予针对特定中国客户的小量H200许可，但中国方面的限制使公司未能出售所有获许可产品；已完成的部分许可项下发货，占最近季度Data Center收入不足1%。8月26日发布的下一季展望仍不假设中国 Data Center compute 收入。这个组合说明少量交货与下一季指引采用什么假设是两件事，不能缩写成“英伟达全部对华营收为零”，更不能说“中国AI需求归零”。NVIDIA 10-Q、NVIDIA 8月26日展望

阅读后续消息时，按“正式规则—个别许可—目的地许可—交货验收—收入回款”逐层记录；任何一层未完成，就不能自动标记下一层完成。

情景（不赋概率）	先核的触发证据	可能改善的方面	可能恶化的方面
部分供给限制缓解	正式规则或具体许可，随后有可验证交付	下游获得更多设备选择，部分建设成本或等待时间下降	国产供应商面临进口竞争、价格与订单压力
限制延续但有个案通道	审查政策稳定，个别许可与实际销售分化	已完成认证的替代方案可能获得持续订单	关键配套仍受限，客户项目可能延误
限制扩大	已生效的规则、清单或正式许可变化	部分替代研发和本地采购动机增强	上游断供、迁移成本、利用率和资本回收可能同时受损

本版删除原先30%/50%/20%的主观权重，也删除“三种情景都有上行机会”的结论。政策带来的情绪交易与公司形成现金流是两件事；没有历史样本和估计程序，这张表只用于压力测试，不能包装成客观概率或直接交易信号。

2.9 我可能错在哪里

模型层的收敛可能被下一次架构或数据突破重新拉开，也可能比现有榜单显示得更快。如果只盯公开英语问答榜，既可能忽视某些领域的落后，也可能漏掉中文与企业专有场景的优势。

国产设备的工程改进也可能快于公开证据出现的速度。本篇对未公开配置不补猜，不意味着断言它没有发生；应把这类信息留在待核层，等待可复核的训练、推理或客户验收材料，而不是先写成确定突破再等待来源。

主权项目不完全服从商业资本回报，安全和公共服务目标可能支持较长的投资周期。因此，单用普通企业回收期判断所有项目都会停工，会低估政策投入的持续性；但政策持续投入同样不能证明每一家供应商估值合理。

最后，出口政策、劳动市场和能源数据的变化速度不同。规则可能当天变化，采购与就业统计需要更长时间出现。下一次更新应分别刷新这几条证据链，不以一个新日期给全部旧数据盖章，也不让一个刚发布的模型覆盖仍然未知的产业结果。

本版逐项修订记录

分册编号勘误 · 2026-09-08

按本册实际收录顺序重排章节，正文目录、网页锚点和PDF书签由同一正文重建；未收录主题改用报告名称指引，不再假设读者手里有母稿。

全景母稿位置	本册位置
第四部分（4.x）	第一章（1.x）
第五部分（5.x）	第二章（2.x）

下列历史修订记录的当前落点已换成本册编号；带“原”“母稿”或描述已删除指引的旧号仍用于追溯。此次只修改编排与定位文字，不重算数据、不改变结论，也不改写冻结记录。

以下保留所选章节的V1.5基础修订记录，并将本轮变更标为V1.5.1；每条对应正文纠错或证据更新。

AGI与国际格局：逐项修订

V1.5.1（10月9日），5.7：新增AMD预发布硬件测试的工作负载、每用户速度和测试日期边界；34倍只属于特定门槛，未转成量产、成本或收益结论。

V1.5.1（10月1日），5.7：加入9月28—29日模型迭代，Rubin由单纯预览证据接续至有限生产使用；列明指定客户、SWE-2、GB200和每GPU口径。修正旧文“提高若干倍”的歧义为“达到基准的若干倍”；V100仍服役不等于租金或项目回报已获证明。

V1.5.1（9月24日），4.2与5.7：加入9月22日模型发布和MLPerf Inference v6.1的Rubin预览结果，保留厂商声明、基准条件与量产部署之间的边界；不据此更新统一AGI年份或已实现利润。

1. **主题回归**：取消旧分项报告前置的大厂财报、融资与股价总览，直接从9月模型能力及其经济含义展开；保留原第四、第五部分全部专题主线。
2. **能力证据更新**：加入9月1日 Anthropic、9月3日 OpenAI 的官方发布和评测限制；撤下未核R2信息及不具可比性的跨基准饱和曲线。
3. **时间表纠正**：撤回未经同口径核验的名人年份、预测市场快照和算力倍数到AGI年份映射，以定义、验收条件和复查证据替代。
4. **估值纠正**：撤回AGI占估值40—60%和延期通常折损40—55%的结论，补入明确假设的三年折现计算，区分受影响现金流与整家公司价值。
5. **国际比较纠正**：删除Elo百分比作为能力差距，保留模型、训练硬件、推理部署及产业兑现的分层框架。
6. **主权项目纠正**：逐项标注Stargate、HUMAIN、InvestAI、IndiaAI的公告日期和规划/运行边界，不重复加总，不把采购计划写成投运事实。
7. **就业更新**：纳入Stanford2026年8月修订的19%相对就业差异，并保留22—25岁、比较组、样本与非因果限制；将Anthropic使用数据和全国就业统计分开。

8. **能源更新**：采用IEA2026版2025年485TWh及2030年950TWh预测，拆开年份、地区和全部数据中心/AI子集；撤销未经核验的核电总量和能源必然受益判断。
9. **政策更新**：修正AI Diffusion时间线，补BIS2026年1月逐案审查、NVIDIA8月披露的许可到收入边界，以及欧盟8月透明度要求；政策情景不再赋主观概率。
10. **修订边界**：新源不改变历史冻结PDF和V1.4，未声称模型已获独立复测、未证明AGI实现、未完成项目逐站验收，也未构成全报告审核通过。原4.10反证小节在本册顺排为1.6（全景母稿4.6），目录随实际正文重建。

本篇V1.5.1修订记录

1. **部署差异。** 第一章开篇与1.3补Google9/2发布，区分基础智能、网络安全防护和用户可访问范围，不新增跨设置排行榜。来源：Google发布原文。
2. **研发进度。** 1.4补特定训练暂停、恢复及仍暂缓的边界，将安全工程纳入进度约束；不把原事件归给Astra，也不外推AGI延期。来源：OpenAI9/1说明。
3. **生态交易。** 2.7补Hugging Face收购的签约、披露和预计交割阶段，以及开放选择承诺，竞争影响按待验证判断处理。来源：SEC交易文件、公司生态说明。
4. **境外总部规则。** 2.8补5/31BIS对既有许可要求的澄清，同时保留例外与存量运行限定，避免把规则宽松或收紧都推成全面结论。来源：BIS指引。本轮保留上述V1.5修订记录，仅更新与本篇主题相关的正文。